# 스마트폰 행동 인식 신경망의 성능·규모 절충과 피험자별 편차 분석

이봉헌(*), 유재윤(**), 정회서(***), 한윤섭(****), 최승빈(*****)
(*, **) 선문대학교 AI소프트웨어학과, {bongbong9292, zoroi24}@naver.com
(***) 선문대학교 AI소프트웨어학과, hoeseo4019@sunmoon.ac.kr
(****, *****) 선문대학교 AI소프트웨어학과, {nfsodv0929, ramongrupy}@gmail.com
지도교수(Supervisor) : 황세웅

## 1. 연구 배경

스마트폰 센서 기반 행동 인식은 이동·운동 상황에 맞춘 서비스의 입력으로 활용할 수 있다. 공개 데이터 연구[1,2]와 CNN·LSTM 기반 연구[3]가 제시되었으며, 모델 구성과 탐색 조건도 비교 결과의 해석에 영향을 준다[4]. 본 연구는 동일 피험자 분할에서 네 신경망 구성의 성능·규모 절충을 비교하고, 전체 평균에 드러나지 않는 행동·피험자별 성능 편차를 분석한다.

## 2. 연구 내용

UCI HAR[1,2]의 걷기·계단 오르기·내리기·앉기·서기·눕기를 사용했다. 입력은 50 Hz로 측정된 128시점×9채널이며 신체 가속도·각속도·총 가속도의 xyz 순서다. 제공 신호의 필터링·50% 중첩 윈도잉을 유지했다. 공식 학습 자료를 학습 16명·5,577구간과 검증 5명·1,775구간(1·6·14·21·23)으로 분리했다. 사람·표본 ID 비중복과 모델 간 ID·정답·해시 일치를 검사하고, 학습 자료의 저장 평균·표준편차로 한 번 표준화했다.

MLP는 Flatten→Dense 128·64 ReLU, CNN은 Conv1D 64(k5)·128(k3)·128(k3)→GAP→Dense 64 ReLU이며 첫 두 합성곱 뒤 Pool 2를 둔다. SimpleRNN은 tanh 은닉 32, LSTM은 은닉 64→Dense 32 ReLU다. 순환 모델은 구간마다 상태를 0으로 초기화하고 마지막 상태를 사용한다. 출력은 6 logits, CNN의 Dense 뒤 Dropout은 0.3이며 나머지는 0이다.

Adam 0.001, batch 64, 최대 40 epoch, logits 기반 희소 교차 엔트로피와 validation loss 기준 early stopping(patience 6, 최선 가중치 복원)을 공통 적용했다. seed 2026·2027·2028의 12회 검증 예측을 재분석했으며 개인 튜닝 결과로 기준 구성을 대체하지 않았다. 클래스별 F1을 균등 평균하는 6클래스 Macro F1을 주 지표로, Accuracy를 보조 지표로 사용한다.

표 1. 개발 검증 성능과 모델 규모

| 모델 조건 | 파라미터 | Accuracy 평균 ± SD | Macro F1 평균 ± SD |
|---|---|---|---|
| MLP M01 | 156,230 | 0.8667 ± 0.0117 | 0.8646 ± 0.0125 |
| CNN C01 | 85,574 | 0.8888 ± 0.0116 | 0.8889 ± 0.0127 |
| RNN R01 | 1,542 | 0.7356 ± 0.0497 | 0.7191 ± 0.0586 |
| LSTM L01 | 21,222 | 0.8832 ± 0.0194 | 0.8813 ± 0.0195 |

표 1의 CNN·LSTM 평균 Macro F1은 0.8889·0.8813(차이 0.0076)이며 LSTM 파라미터는 75.2% 적다. 작은 모델로 전환할 때의 성능·규모 절충을 보여준다. SD는 같은 사람 분할에서 세 seed의 표본 표준편차다.

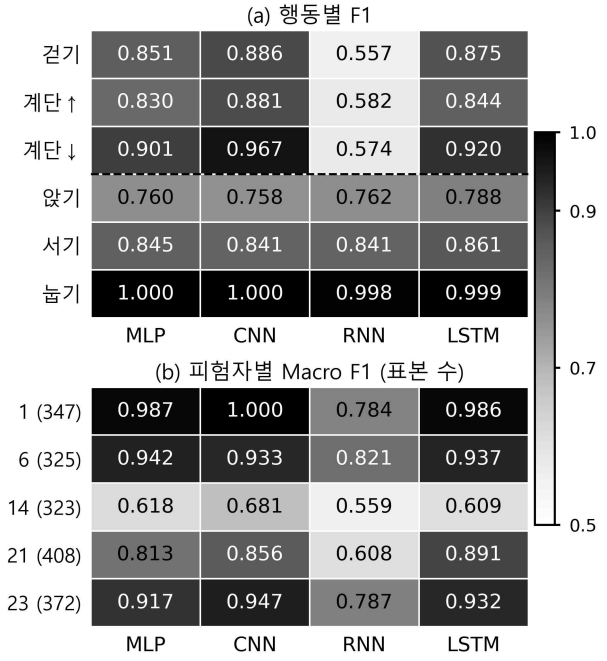



그림 1. 행동별·피험자별 F1의 세 seed 평균

그림 1(a)의 6클래스 F1 중 동적 세 행동(점선 위)·정적 세 자세의 평균은 CNN 0.9115·0.8662, LSTM 0.8798·0.8828로 평균 순위가 바뀌었다. RNN도 동적 0.5711·정적 0.8671의 차이가 커 전체 점수만으로 행동별 성능을 설명하기 어려웠다.

그림 1(b)는 각 피험자의 6클래스 Macro F1이다. 피험자 14(323구간)는 네 구성 모두 최저(0.5593–0.6812)였으며 LSTM도 전체 0.8813에 비해 0.6089로 낮았다. 평균 점수에 가려진 개인별 성능 저하를 보여준다.

앉기→서기 오류는 원논문[1]에서도 보고한 자세 혼동이다. LSTM의 오류율은 매 seed의 실제 앉기 309구간에서 평균 31.3%였으나, 9.7–47.9%로 변동했다(SD 19.6%p). 평균만으로 안정적인 자세 분류를 주장하기 어렵다.

## 3. 현실적 제한 조건에 대한 검토

개발 검증은 epoch 선택에도 사용했으며 공식 test는 미평가다. 단일 분할·세 seed와 사후 분석으로 일반화·유의성·동등성을 결론낼 수 없다.

용량·헤드·Dropout·탐색 예산의 차이로 구조 효과를 분리하지 못했으며 오류 원인·스마트폰 속도·전력은 미측정이다.

## 4. 기대효과 및 활용

평균 성능·모델 규모·오류 위치를 함께 고려한 모델 선정과 후속 검증의 근거를 제공한다.

## 5. 결론

CNN이 평균 F1에서 높았고 LSTM은 75.2% 적은 파라미터를 사용했다. 행동군의 평균 순위 변화와 취약 피험자는 평균 이외의 평가 필요성을 보여준다. 복수 사람 분할·독립 평가는 후속 과제다.

## 참고 문헌

[1] D. Anguita et al., “A Public Domain Dataset for Human Activity Recognition Using Smartphones,” ESANN, pp. 437–442, 2013.

[2] J. L. Reyes-Ortiz et al., “Human Activity Recognition Using Smartphones,” UCI Machine Learning Repository, 2013. DOI: 10.24432/C54S4K.

[3] F. J. Ordóñez and D. Roggen, “Deep Convolutional and LSTM Recurrent Neural Networks for Multimodal Wearable Activity Recognition,” Sensors, 16(1), 115, 2016.

[4] N. Y. Hammerla et al., “Deep, Convolutional, and Recurrent Models for Human Activity Recognition using Wearables,” arXiv:1604.08880, 2016.

## 감사의 글

연구 지원 적용 여부와 학교 사사 문구 확인 후 최종 기재할 예정이다.