스마트폰 행동 인식 신경망의 성능·규모 절충과 피험자별 편차 분석

이봉헌(*), 유재윤(**), 정회서(***), 한윤섭(****), 최승빈(*****)
(*, **) 선문대학교 AI소프트웨어학과, {bongbong9292, zoroi24}@naver.com
(***) 선문대학교 AI소프트웨어학과, hoeseo4019@sunmoon.ac.kr
(****, *****) 선문대학교 AI소프트웨어학과, {nfsodv0929, ramongrupy}@gmail.com
지도교수(Supervisor) : 황세웅

1. 연구 배경

스마트폰 관성센서 기반 행동 인식은 일상 동작을 시계열로 분류하는 기술이다[1]. 모델 선택에는 평균 성능과 모델 규모, 미지 사용자에 대한 성능을 함께 고려해야 한다. Scheurer 등[2]은 사람 의존·독립 평가와 모델 개인화 방식을 구분해 비교하였다. 본 연구는 동일 입력·사람 분할에서 네 기준 신경망 구성을 반복 평가하고, 성능·규모 절충 및 피험자별 편차를 분석한다. 또한 저장 예측의 피험자 제외 진단으로 검증 구성에 따른 평균 순위의 민감도를 확인한다.

2. 연구 내용

2.1 데이터와 전처리

UCI HAR[1]의 걷기·계단 오르기·내리기·앉기·서기·눕기 6클래스를 50Hz·128시점×9채널(신체 가속도·각속도·총 가속도의 xyz)로 입력했다. 제공 신호의 필터링·50% 중첩은 유지했다. 공식 학습 자료를 학습 16명·5,577구간, 검증 5명·1,775구간(1·6·14·21·23)으로 나누고 사람·표본 ID 비중복과 모델 간 정합성을 검사했다. 저장된 학습 평균·표준편차로 한 번 표준화했다.

2.2 모델과 학습·평가 조건

Adam 0.001, batch 64, 최대 40 epoch, logits 기반 희소 교차 엔트로피와 검증 손실 기준 early stopping(patience 6, 최선 복원)을 적용했다. 네 기준 구성을 seed 2026·2027·2028로 반복한 12회 예측을 평가했다. Macro F1은 6개 클래스 F1의 산술평균으로 각 클래스를 동일하게 반영한다. 학습을 고정한 채 검증 피험자를 한 명씩 제외하는 진단도 수행했다.

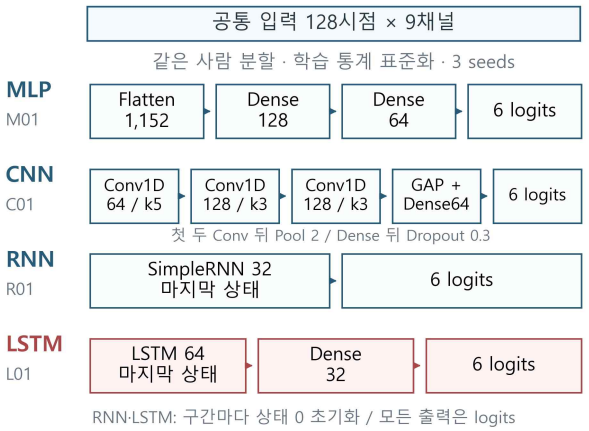


그림 1. 고정 네 기준 구성의 입력·분류 구조

은닉 Dense는 ReLU, SimpleRNN은 tanh다. 순환 모델은 구간별 상태를 0으로 초기화하고 마지막 상태를 사용한다. CNN의 Dense 뒤 Dropout은 0.3, 나머지 기준 조건은 0이다.

2.3 개발 성능 및 피험자별 분석

CNN의 평균 Macro F1은 0.8889로 가장 높았다(표 1). LSTM은 0.8813로 0.0076 낮으나 파라미터는 75.2% 적었다. 표의 ±는 seed 표본 SD다.

표 1. 개발 검증 성능과 모델 규모

모델·조건	파라미터	Macro F1 평균 ± SD
MLP M01	156,230	0.8646 ± 0.0125
CNN C01	85,574	0.8889 ± 0.0127
RNN R01	1,542	0.7191 ± 0.0586
LSTM L01	21,222	0.8813 ± 0.0195

RNN의 Macro F1 평균은 0.7191, seed 표본 SD는 0.0586로 네 기준 구성 중 변동이 가장 컸다.

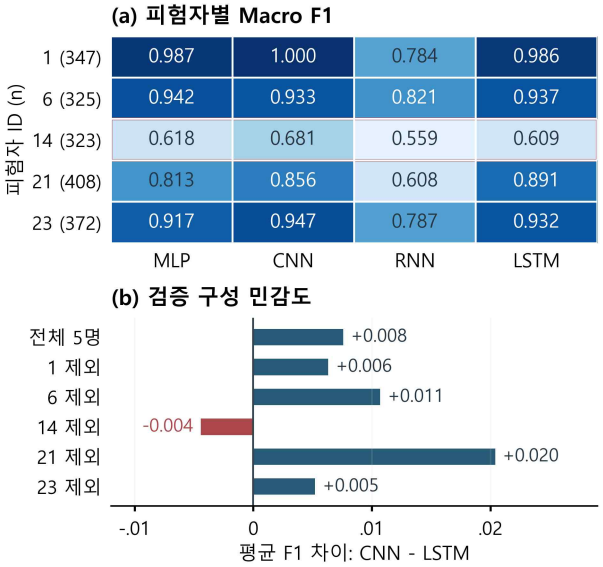


그림 2. 피험자별 F1 평균과 검증 구성 민감도

피험자 내부 Macro F1에서 14(323구간)는 네 구성 모두 최저(0.5593–0.6812)였다(그림 2(a)). LSTM도 전체 0.8813에 비해 0.6089로 낮았다.

피험자 14 제외 시 CNN·LSTM 평균은 0.9290·0.9334로 순위가 바뀌었다(그림 2(b)). 표본·클래스 구성도 변하므로 인과 효과나 성능 개선은 아니다. 대표 결과는 전체 5명을 유지한다.

3. 현실적 제한 조건에 대한 검토

(1) 평가: 검증은 epoch 선택에 사용한 개발용이며 공식 test는 미평가다. 단일 분할·세 seed로 모집단 일반화나 통계적 동등성을 판단하기 어렵다.

(2) 비교 조건: 용량·헤드·Dropout·탐색 예산이 달라 순수 구조 효과를 분리하지 못했다. 오류 원인과 실제 기기의 속도·전력도 미측정이다.

4. 기대효과 및 활용

개발 단계에서 평균 성능을 우선할 때 CNN을, 파라미터 규모를 함께 고려할 때 LSTM을 후속 검증 후보로 검토할 수 있다. 피험자별 진단은 전체 평균에 가려진 취약 사용자를 찾고, 집단별 평가를 모델 선정 절차에 포함하는 근거를 제공한다.

5. 결론

동일 개발 분할에서 CNN의 평균 Macro F1이 가장 높았고, LSTM은 75.2% 적은 파라미터로 0.0076의 차이를 보였다. 공통 취약 피험자와 검증 구성에 따른 순위 변화도 확인했다. 복수 사람 분할·독립 평가를 통해 모델 선정의 안정성을 검증할 필요가 있다.

참고 문헌

[1] J. L. Reyes-Ortiz et al., “Human Activity Recognition Using Smartphones,” UCI Machine Learning Repository, 2013. DOI: 10.24432/C54S4K.

[2] S. Scheurer et al., “Comparing Person-Specific and Independent Models on Subject-Dependent and Independent Human Activity Recognition Performance,” Sensors, 20(13), 3647, 2020.

감사의 글

연구 지원 적용 여부와 학교 사사 문구 확인 후 최종 기재할 예정이다.