스마트폰 센서 기반 활동 요약을 위한 분류 목표와 모델 구성 비교

이봉헌(*), 유재윤(**), 정회서(***), 한윤섭(****), 최승빈(*****)
(*, **) 선문대학교 AI소프트웨어학과, {bongbong9292, zoroi24}@naver.com
(***) 선문대학교 AI소프트웨어학과, hoeseo4019@sunmoon.ac.kr
(****, *****) 선문대학교 AI소프트웨어학과, {nfsodv0929, ramongrupy}@gmail.com
지도교수(Supervisor) : 황세웅, indimoa@gmail.com

1. 연구 배경

스마트폰 활동 기록은 필요한 행동 구분 수준에 따라 분류 목표가 달라진다. 기존 연구는 계층적 특징 선택[2]과 소수 특징의 선형 분류[3]를 제시했다. 본 연구는 6종 행동과 3상태 요약을 구분하고, 예측 병합과 직접 학습을 대조한다. 같은 특징의 분류기와 사람 독립 test·처리 비용을 결합해 출력 요구에 따른 구성 선택 근거를 제시한다.

2. 연구 내용

2.1 데이터와 실험 조건

UCI HAR[1]의 허리 착용 스마트폰 신체·총 가속도와 각속도 9채널(50Hz, 128시점, 50% 중첩)을 사용했다. 학습 16명·5,577구간, 검증 5명·1,775구간으로 나누고 조건·모델 고정 후 공식 test 9명·2,947구간을 평가했다. 사람·원 행 중복과 원본 신호·라벨을 대조하고 학습 통계로 표준화했다. Macro F1은 목표 클래스별 F1의 산술평균이다.

걷기·계단 오르기·내리기를 이동, 앉기·서기를 앉거나 서 있음, 눕기를 누워 있음으로 정의했다. 6종 argmax의 상태 병합과 3상태 직접 학습을 비교했다. 선형 로지스틱 회귀(LR3)와 특징 MLP(FMLP3, 18→128→64→3)는 같은 채널 평균·표준편차 18개, 특징 표준화 통계와 정답을 사용했다. LR은 L2, C=1, lbfgs로 한 번 학습했다.

시계열 MLP(128→64), CNN(64/128/128→64), RNN(32), LSTM(64→32)은 기존 6종 모델과 3출력 학습 조건을 사용했다. CNN의 Dropout은 0.3이다. NN은 Adam 0.001, batch 64, 최대 40 epoch, 검증 손실 patience 6·최선 복원, seed 2026~2028을 적용했다. 개발 비교 뒤 추가 NN 15회와 평가 구성을 고정하여 모든 seed의 test를 보고했다.

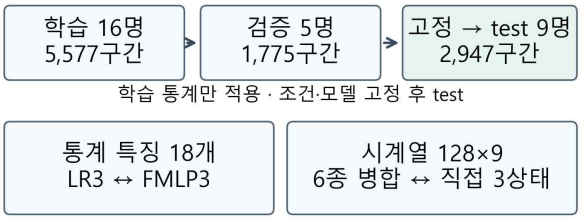


그림 1. 사람 분리와 입력·학습 목표의 대조

2.2 공식 test 결과

표 1. 공식 test Macro F1 (NN 평균±표본 SD)

모델	6종	6종→3	직접 3
MLP	0.8816 ±0.0164	0.9796 ±0.0031	0.9918 ±0.0024
CNN	0.9053 ±0.0136	0.9950 ±0.0027	0.9962 ±0.0028
RNN	0.7217 ±0.0669	0.9788 ±0.0076	0.9905 ±0.0027
LSTM	0.8767 ±0.0183	0.9866 ±0.0065	0.9959 ±0.0029
LR	0.7486	0.9865	0.9994
FMLP	-	-	0.9986 ±0.0002

6종 F1은 CNN 0.9053, LR6 0.7486이었다. 직접 3상태는 모든 구성에서 0.9905~0.9994로 높았다. 네 NN은 병합보다 평균 F1이 높고 같은 seed 12쌍 중 11쌍에서 증가했다(LSTM 2027: −0.0011). 동일 특징의 LR3·FMLP3는 0.9994·0.9986이었다. LR3 오류 2구간은 사람 9의 앉기를 이동으로 예측한 경우다. NN은 평균±표본 SD, LR은 단일 학습이다.

2.3 준비된 센서 구간의 처리 비용

공통 평가는 Intel Core i9-13980HX CPU(연산 4·상호 1스레드), Python 3.11.9, TensorFlow 2.21.0, Keras 3.15.1, NumPy 2.2.6을 사용했다. LR 학습은 scikit-learn 1.7.2이다. 탑재 GPU는 RTX 4060 Laptop이며 평가에는 사용하지 않았다. 검증 첫 구간을 batch 1, 워밍업 50회 후 500회 측정했다. 전처리·특징·분류·반환 시간은 LR3 0.073ms, FMLP3 1.043ms였다. 각 실행 중앙값의 중앙값이며 수집·필터링·구간화·초기 로딩은 제외했다.

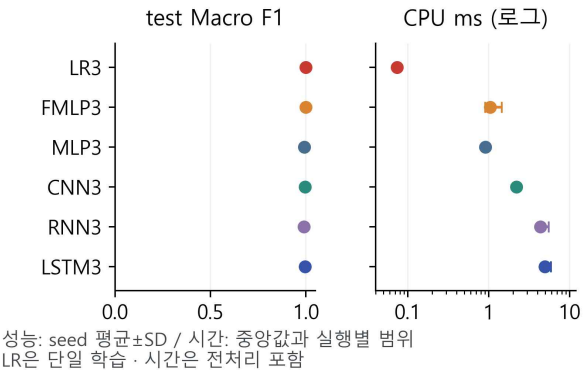


그림 2. 3상태 성능과 CPU 처리 비용

3. 평가 범위와 결과 해석

3상태 F1이 높은 구간에 밀집해 작은 점수 차이를 모델 우월성으로 해석하지 않는다. 동일 특징 LR3·FMLP3의 파라미터는 57·10,883개, 처리 시간은 약 14.2배 차이였다. 이는 고정 구성의 관측 비용이며 통계적 성능 동등성이나 스마트폰 성능을 뜻하지 않는다. 평가 범위는 허리 착용 6동작이고, seed SD는 고정 test의 학습 변동이다.

4. 기대효과 및 활용

카메라·GPS 없이 구간별 이동·앉거나 서 있음·누워 있음 태그를 부여하는 활동 요약에 연결한다. 이 목표에서는 높은 분류 성능을 보인 단순 구성의 비용을 검토할 근거가 있다. 좌식 시간이나 계단 이용 기록은 앉기·서기와 이동 세부 라벨을 유지해 6종 지표로 선택한다. 누워 있음은 자세 라벨이다.

5. 결론

직접 3상태는 모든 구성에서 높은 F1을 보였으나 처리 비용은 달랐다. 6종에서는 CNN 0.9053과 LR6 0.7486으로 결과가 달라졌다. 본 연구는 보존할 행동 정보를 먼저 정하고, 해당 목표에서 높은 성능을 보인 구성의 비용을 비교하는 선택 근거를 제시했다.

참고 문헌

[1] J. L. Reyes-Ortiz et al., “Human Activity Recognition Using Smartphones,” UCI, 2013. DOI: 10.24432/C54S4K.

[2] A. Wang et al., “Towards Human Activity Recognition: A Hierarchical Feature Selection Framework,” Sensors, 18(11), 3629, 2018.

[3] I. Debache et al., “A Lean and Performant Hierarchical Model for Human Activity Recognition Using Body-Mounted Sensors,” Sensors, 20(11), 3090, 2020.

github.com/kara320090/smartphone-har

감사의 글

본 연구는 2026년도 과학기술정보통신부 및 정보통신기획평가원의 ‘SW중심대학지원사업’의 연구 결과로 수행되었습니다(2024-0-00023).